

Министерство цифрового развития, связи и  
массовых коммуникаций Российской Федерации

Федеральное государственное бюджетное образовательное учреждение  
высшего образования «Сибирский государственный университет  
телекоммуникаций и информатики» (СибГУТИ)

**ЛАБОРАТОРНАЯ РАБОТА №5**  
по дисциплине «Моделирование»

Выполнил:  
студент гр. ИС-142  
«\_\_» мая 2025 г.

\_\_\_\_\_ /Григорьев Ю.В./

Проверил:  
преподаватель  
«\_\_» мая 2025 г.

\_\_\_\_\_ /Уженцева А.В./

Оценка « \_\_\_\_\_ »

Новосибирск 2025

## ВВЕДЕНИЕ

Цепи Маркова представляют собой важный инструмент в теории вероятностей и математическом моделировании, находящий широкий спектр применения в таких областях, как физика, биология, экономика и информатика. Рандомизированная цепь Маркова (РЦМ) — это дискретная стохастическая модель, в которой переходы между состояниями определяются случайным образом на основе заданной матрицы вероятностей переходов. Особенностью двухстохастических матриц, используемых в данной работе, является то, что сумма элементов как по строкам, так и по столбцам равна единице, что накладывает дополнительные ограничения на структуру переходов и стационарное распределение.

Целью данной работы является реализация модели РЦМ с использованием языка программирования Python и библиотеки Matplotlib для визуализации результатов. Задание включает создание двух различных двухстохастических матриц, генерацию последовательностей состояний и связанных с ними случайных значений, нормировку данных, анализ частот посещений состояний, а также построение графиков поведения и автокорреляции. В рамках работы исследуется влияние структуры матриц переходов на динамику цепи Маркова, что позволяет глубже понять зависимость поведения модели от её параметров.

## ВЫПОЛНЕНИЕ РАБОТЫ

Для выполнения работы были выбраны две матрицы с принципиально разными характеристиками: первая матрица демонстрирует сильную склонность к сохранению текущего состояния (высокие диагональные элементы), вторая — более равномерное распределение вероятностей переходов. Такой выбор позволяет сравнить контрастные сценарии поведения РЦМ и оценить их влияние на итоговые характеристики модели. Программа реализована на Python с использованием библиотек NumPy для работы с массивами и генерации случайных чисел, а также Matplotlib для построения графиков. Основные этапы работы включают:

1. Определение и проверка двухстохастических матриц.
2. Генерация цепей Маркова с использованием экспоненциального распределения для значений.
3. Нормировка сгенерированных значений в диапазон  $[0, 1]$ .
4. Подсчёт частот посещений состояний.
5. Визуализация поведения цепей и их автокорреляции.

### 1. Описание матриц переходов

Для исследования были выбраны две двухстохастические матрицы:

**Матрица P1:**

$$\begin{bmatrix} 0.8 & 0.1 & 0.1 \\ 0.1 & 0.8 & 0.1 \\ 0.1 & 0.1 & 0.8 \end{bmatrix}$$

Эта матрица характеризуется высокими значениями на главной диагонали (0.8), что означает высокую вероятность (80%) остаться в текущем состоянии. Вероятность перехода в другие состояния составляет всего 10% для каждого. Такая структура предполагает "инерционное" поведение цепи, где состояния меняются редко.

**Матрица P2:**

$$\begin{bmatrix} 0.2 & 0.4 & 0.4 \\ 0.4 & 0.2 & 0.4 \\ 0.4 & 0.4 & 0.2 \end{bmatrix}$$

В отличие от P1, эта матрица демонстрирует более равномерное распределение вероятностей переходов. Вероятность остаться в текущем состоянии составляет 20%, а вероятность перейти в любое из двух других состояний — 40%. Это обеспечивает более динамичное и сбалансированное поведение цепи.

Обе матрицы были проверены на двухстохастичность: суммы по строкам и столбцам равны 1, что подтверждает корректность их построения.

## 2. Реализация алгоритма

Алгоритм генерации цепи Маркова реализован в функции `generate_markov_chain`. Начальное состояние задается как 0, а затем на каждом из 100 шагов:


- Генерируется случайное значение из экспоненциального распределения с параметром `scale=1.0`.
- На основе текущего состояния и соответствующей строки матрицы переходов выбирается следующее состояние с помощью функции `np.random.choice`.
- Значения нормируются в диапазон `[0, 1]` для унификации анализа.

Частоты посещений состояний вычисляются как доля шагов, проведённых в каждом состоянии, с использованием функции `np.bincount`. Для визуализации строятся два графика: график поведения (нормированные


значения в зависимости от шага) и график автокорреляции (зависимость значений от предыдущих на разных лагах).

3. Визуализация

Сравнение поведения двух цепей Маркова



Автокорреляция цепей Маркова



Общее число шагов моделирования составило 100, что достаточно для демонстрации различий в поведении цепей.

## Выводы в консоль:

[illegible]

## 4. Результаты моделирования

## 4.1. Поведение цепей

Для матрицы **P1** последовательность состояний демонстрировала длительные периоды пребывания в одном состоянии, например, [0, 0, 0, 0, 1, 1, 1, 1, 2, 2, ...]. Это ожидаемо, учитывая высокую вероятность сохранения состояния. Частоты посещений могли быть неравномерными (например, 0.39, 0.47, 0.14), так как цепь могла "застрять" в одном состоянии из-за случайного характера генерации.

Для матрицы **P2** состояния сменялись чаще и более равномерно, например, [0, 1, 2, 1, 0, 2, 1, ...]. Частоты посещений были близки к равномерному распределению (примерно 0.33 для каждого состояния), что

соответствует симметричной структуре матрицы и её стационарному распределению.

График поведения (нормированных значений) показал, что цепь для **P1** имеет более "ступенчатую" динамику с редкими резкими изменениями, тогда как цепь для **P2** демонстрирует более хаотичное и плавное изменение значений. Это отражает различия в интенсивности переходов.

#### **4.2. Автокорреляция**

Автокорреляция для **P1** медленно менялась, что указывает на сильную зависимость значений от предыдущих из-за редких смен состояний. Для **P2** автокорреляция изменяется быстрее, что свидетельствует о меньшей зависимости между шагами и более случайном характере цепи.

#### **4.3. Влияние структуры матриц**

Матрица **P1** с высокой диагональной вероятностью приводит к "вязкому" поведению цепи, где изменения редки, а система обладает значительной инерцией. Это может быть полезно для моделирования процессов с сильной памятью или стабильностью (например, физических систем с низкой подвижностью). Матрица **P2**, напротив, моделирует более подвижную систему с частыми переходами, что характерно для процессов с высокой степенью случайности (например, социальные взаимодействия или финансовые рынки).

### **ЗАКЛЮЧЕНИЕ**

В ходе выполнения работы была успешно реализована модель рандомизированной цепи Маркова с использованием двух различных двухстохастических матриц. Анализ результатов подтвердил значительное влияние структуры матрицы переходов на динамику цепи. Матрица с высокой вероятностью сохранения состояния (**P1**) привела к инерционному поведению с редкими переходами и высокой автокорреляцией, тогда как матрица с равномерными переходами (**P2**) обеспечила более динамичную и случайную последовательность с быстрым спадом автокорреляции.

Полученные данные демонстрируют, как параметры модели могут быть адаптированы для описания различных реальных процессов. Например, матрицы типа **P1** подходят для систем с устойчивостью, а матрицы типа **P2** — для систем с более высокой вариабельностью. Построенные графики и вычисления частот позволили наглядно оценить различия в поведении цепей, что подчеркивает важность выбора подходящей матрицы переходов в задачах моделирования.

Работа также выявила потенциал для дальнейших исследований: увеличение числа шагов, использование других распределений (например, равномерного вместо экспоненциального) или расширение размерности матриц могут дать более глубокое понимание свойств РЦМ. В целом, задание позволило закрепить навыки программирования, анализа данных и визуализации, а также углубить теоретические знания о цепях Маркова.

## Приложение.

### Листинг программы

```
import numpy as np
import matplotlib.pyplot as plt

np.random.seed(42)

P1 = np.array([
    [0.8, 0.1, 0.1],
    [0.1, 0.8, 0.1],
    [0.1, 0.1, 0.8]
])

P2 = np.array([
    [0.2, 0.4, 0.4],
    [0.4, 0.2, 0.4],
    [0.4, 0.4, 0.2]
])

print("Проверка P1:")
print("Сумма по строкам:", np.sum(P1, axis=1).tolist())
print("Сумма по столбцам:", np.sum(P1, axis=0).tolist())
print("Проверка P2:")
print("Сумма по строкам:", np.sum(P2, axis=1).tolist())
print("Сумма по столбцам:", np.sum(P2, axis=0).tolist())

def generate_markov_chain(P, n_steps, initial_state=0):
    states = [initial_state] # Список состояний
    values = [] # Сгенерированные значения

    for _ in range(n_steps):
        # Генерируем случайное значение из экспоненциального распределения
        val = np.random.exponential(scale=1.0)
        values.append(val)
        # Переход в следующее состояние на основе текущего
        current_state = states[-1]
        next_state = np.random.choice([0, 1, 2], p=P[current_state])
        states.append(next_state)

    # Нормируем значения (приводим к диапазону 0-1)
    values = np.array(values)
    values = (values - values.min()) / (values.max() - values.min())
    return states, values

n_steps = 100 # Количество шагов
states1, values1 = generate_markov_chain(P1, n_steps)
states2, values2 = generate_markov_chain(P2, n_steps)

freq1 = np.bincount(states1, minlength=3) / len(states1)
freq2 = np.bincount(states2, minlength=3) / len(states2)

print("\nМатрица P1:")
print(P1)
```

```

print("Сгенерированные значения:", values1.tolist())
print("Переходы:", [int(s) for s in states1])
print("Частоты состояний:", freq1.tolist())

print("\nМатрица P2:")
print(P2)
print("Сгенерированные значения:", values2.tolist())
print("Переходы:", [int(s) for s in states2])
print("Частоты состояний:", freq2.tolist())

plt.figure(figsize=(12, 6))
plt.plot(values1, label="Цепь 1 (P1)", alpha=0.7)
plt.plot(values2, label="Цепь 2 (P2)", alpha=0.7)
plt.title("Сравнение поведения двух цепей Маркова")
plt.xlabel("Шаг")
plt.ylabel("Нормированное значение")
plt.legend()
plt.grid(True)
plt.show()

def autocorrelation(x, max_lag=20):
    n = len(x)
    mean = np.mean(x)
    var = np.var(x)
    acf = []
    for lag in range(max_lag + 1):
        cov = np.sum((x[:n-lag] - mean) * (x[lag:] - mean)) / n
        acf.append(cov / var)
    return np.array(acf)

acf1 = autocorrelation(values1)
acf2 = autocorrelation(values2)

plt.figure(figsize=(12, 6))
plt.plot(acf1, label="Автокорреляция Цепи 1 (P1)", marker='o')
plt.plot(acf2, label="Автокорреляция Цепи 2 (P2)", marker='o')
plt.title("Автокорреляция цепей Маркова")
plt.xlabel("Лag")
plt.ylabel("Значение автокорреляции")
plt.legend()
plt.grid(True)
plt.show()

```